

Classification binaire

- ▶ (X, Y) couple de v.a. de distribution P **inconnue**
- ▶ $Y \in \{-1, +1\}$ est une **étiquette** binaire
- ▶ $X \in \mathbb{R}^d$ modélise une observation permettant de prédire Y

Un exemple: l'algorithme du
Perceptron pour la
classification

Classification

Séparateurs affines

Le Perceptron
mono-couche

Objectif

Construire $g : \mathbb{R}^d \rightarrow \mathbb{R}$ de façon à minimiser l'**erreur de classification**

$$L(g) = \mathbb{P}\{Y \neq g(X)\}$$

Exemples

- ▶ Diagnostic médical
- ▶ Ciblage marketing
- ▶ Risque de crédit

Règle optimale

- Probabilité a posteriori

$$\forall x \in \mathbb{R}^d, \quad \eta(x) = \mathbb{P}\{Y = +1 \mid X = x\}$$

- Règle naïve de Bayes

$$\forall x \in \mathbb{R}^d, \quad g^*(x) = 2\mathbb{I}\{\eta(x) > 1/2\} - 1$$

Risque minimum

$$L(g^*) = \min_g L(g)$$

- L'erreur $L(g)$ est **inconnue**... comme P !

Un exemple: l'algorithme du
Perceptron pour la
classification

Classification

Séparateurs affines

Le Perceptron
mono-couche

Stéphan Cléménçon

Minimisation du Risque Empirique

- ▶ Données observées

$$(X_1, Y_1) \dots, (X_n, Y_n)$$

- ▶ On cherche à concevoir un algorithme qui "minimise" le **risque empirique**

$$\hat{L}_n(g) = \frac{1}{n} \sum_{i=1}^n \mathbb{I}\{Y_i \neq g(X_i)\}$$

sur une collection "pas trop complexe" de règles \mathcal{G}

- ▶ Minimiseur du risque empirique sur \mathcal{G}

$$\hat{g}_n = \arg \min_{g \in \mathcal{G}} \hat{L}_n(g)$$

Un exemple: l'algorithme du
Perceptron pour la
classification

Classification

Séparateurs affines

Le Perceptron
mono-couche

Minimisation du Risque Empirique - Propriétés

Un exemple: l'algorithme du Perceptron pour la classification

Classification

Séparateurs affines

Le Perceptron mono-couche

$$L(\hat{g}_n) - L(g^*) \leq 2 \sup_{g \in \mathcal{G}} |L_n(g) - L(g)| + \left(\inf_{g \in \mathcal{G}} L(g) - L^* \right)$$

Contrôle de la complexité :

$$\mathbb{E} \left[\sup_{g \in \mathcal{G}} |L_n(g) - L(g)| \right] \leq C \sqrt{\frac{V}{n}}$$


si la **dimension de Vapnik-Chervonenkis** de \mathcal{G} est finie, égale à V .

Hyperplans séparateurs

- ▶ On cherche à séparer l'espace d'entrée \mathbb{R}^d en deux régions par un **hyperplan affine** : $(w, \theta) \in \mathbb{R}^d \times \mathbb{R}$

$$\mathcal{H}_{w,\theta} : {}^t w \cdot X + \theta = 0$$

- ▶ Règle associée : $g_{w,\theta}(X) = \text{sign}({}^t w \cdot X + \theta)$



Un exemple: l'algorithme du
Perceptron pour la
classification

Classification

Séparateurs affines

Le Perceptron
mono-couche

Stéphan Cléménçon

Le Perceptron de F. Rosenblatt (1957)

- On remplace

$$\frac{1}{n} \sum_{i=1}^n \mathbb{I}\{-Y_i({}^t w \cdot X_i + \theta) > 0\},$$

par la fonction lisse

$$-\frac{1}{n} \sum_{i=1}^n Y_i({}^t w \cdot X_i + \theta)$$

1. Initialisation : (w, θ) choisi au hasard
2. On tire au hasard (X_i, Y_i) :
 - Si la règle courante classe correctement le point choisi, on ne modifie pas l'hyperplan
 - Sinon, on effectue une **descente de gradient** de pas ρ

$$\begin{pmatrix} w \\ \theta \end{pmatrix} \leftarrow \begin{pmatrix} w \\ \theta \end{pmatrix} + \rho \begin{pmatrix} Y_i X_i \\ Y_i \end{pmatrix}$$

Un exemple: l'algorithme du
Perceptron pour la
classification

Classification


Séparateurs affines

Le Perceptron
mono-couche

Stéphan Cléménçon

Propriétés

- ▶ L'algorithme converge ssi les données sont **linéairement séparables**
- ▶ Cas "linéairement séparable" : le nombre d'itérations de l'algorithme peut être contrôlé (Théorème de Novikoff, '62)
- ▶ L'algorithme s'adapte immédiatement au cas **séquentiel**
- ▶ Extensions : Réseaux de Neurones, Machines à vecteurs support (SVM)



Un exemple: l'algorithme du
Perceptron pour la
classification

Classification

Séparateurs affines

Le Perceptron
mono-couche

Stéphane Cléménçon